I salari del data scientist

Ye Zhongping

1. Introduzione

La data science o scienze dei dati è l'insieme di principi metodologici e di tecniche multidisciplinari che punta a interpretare ed estrarre conoscenza dei dati, attraverso l'analisi di un esperto, il Data scientist.

Il compito del Data scientist è saper gestire i Big Data (dati in grandi quantità), strutturati e non strutturati) e tranne indicazioni utili per l'attività e il successo dell'organizzazioni per cui lavora. Deve coniugare le skill tecniche e l'intuizione per organizzare grandi set di dati e rispondere a domanda complesse, elaborando report che aiutano i top manager a definire le strategie.

2. Selezione e organizzazione dei dati

Il dataset iniziale contava il salario di 3755 data scientist.

L'analisi verrà condotto su 3755 osservazioni e 11 variabili (tabella 2.1)

Tabella 2.1

Nome delle variabile	**Unità di misura e descrizione**
Work_year	L'anno in cui è stato pagato lo stipendio
Experience_level	Il livello di esperienza nel lavoro durante l'anno
Employment_type	Il tipo di impiego per il ruolo
Job_title	Il ruolo svolto durante l'anno
salary	L'importo totale lordo dello stipendio pagato

Salary_currency	La valuta dello stipendio pagato come codice valuta iso 4217
Salary_in_usd	Lo stipendio in USD
Employee_residence	Il paese di residenza principale del dipendente durante l'anno lavorativo come codice paese ISO 3166
Remote_ratio	La quantità complessiva di lavoro svolto in remoto
Campany_location	Il paese dell'ufficio principale o della filiale contraente del datore di lavoro
Campany_size	Il numero mediano di persone che hanno lavorato per l'azienda durante l'anno

E poi si ha raggruppato una nuova tabella(info1) che ha 3755 osservazione e 3 variabili. I tre 2ariabilis ono: experience_level, employment_type e salary_in_usd.

Il variabile experience_level viene divide in 4 sottogruppi: (Tabella2.2)

EN (Entry Level)	Livello base
MI (Mid Level)	Livello medio
SE (Senior Level)	Livello senior
EX (Executive Level)	Livello esecutivo

Il variabile employment_type viene divide in 4 sottogruppi:

FT(Full-time)	Full-time
PT(part-time)	Part-time
CT(contract basis)	Contratto base

FL(Freenlancer)	Freenlancer

3. Descrizione univariata della variabili

I salari di data scientist si possono suddividere in livello di esperienza (EN,MI,SE,EX) e in tipo di impiego (FT,PT,CT,FL).

Le variabili dunque sono:
- Livello di esperienza: variabili qualitativa
- Tipo di impiego: variabili qualitativa

I dati sono scaricati dal sito kaggle con il titolo "Data science salaries 2023". Il dataset iniziale si chiama ds_salaries e lo importo nel Rstudio e rinomina con il nome "ds".

3.1 Interpretazione

Con la tabella info1, possiamo creare il box-plot in base al livello di esperienza (Figura3.1) e in base al tipo di impiego(Figura3.2).

Figura3.1

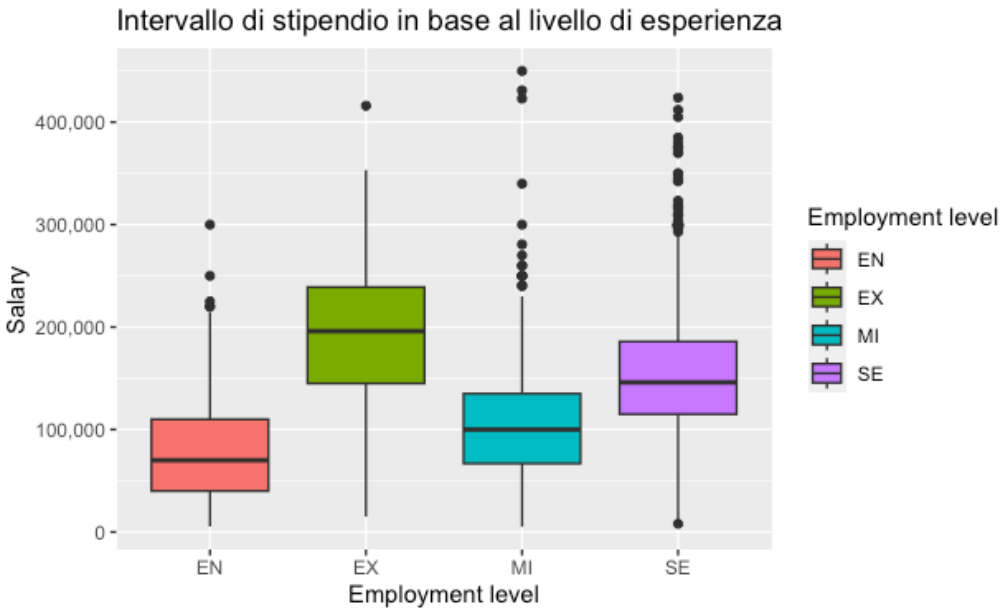

Figura3.2

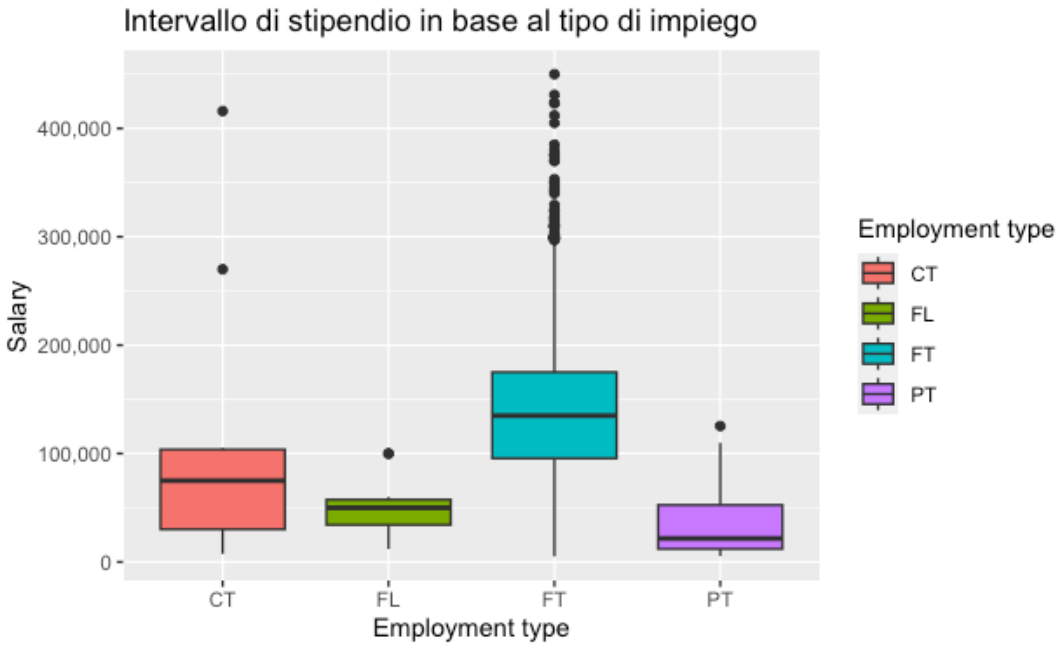

Il box-plot raffigura il massimo, il minimo, la mediana e i quartili.
Il box-plot, chiamato anche diagramma a scatola e baffi, ha:

- Due baffi: che di solito coincidono con il massimo e il minimo, ma in questi casi, il massimo non coincide con il baffo superiore, ma è l'outlier in alto;
- La scatola, che ha estremi che coincidono con il primo e il terzo quartile e al suo interno il secondo quantile (detta anche la mediana).

Si può inoltre fare il grafico dell'istogramma (Figura 3.3)

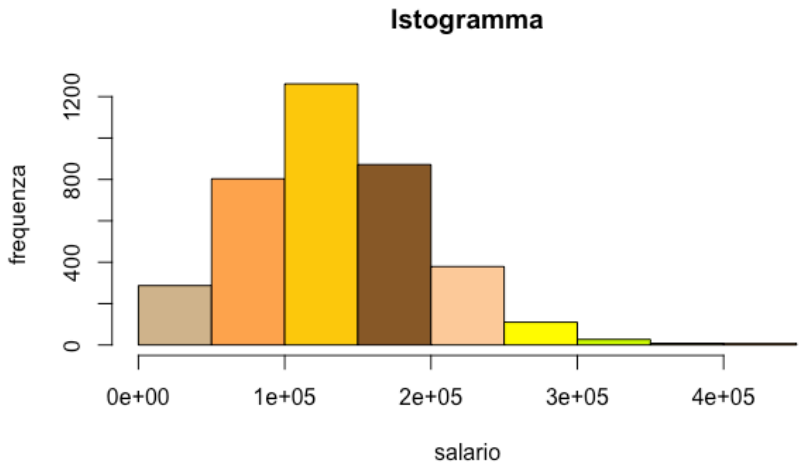

Dal grafico, possiamo capire che la classe più frequente è quel persone che ha il salario circa tra 100000 e 150000.

Le seguente tabella presenta la frequenza assolute dei salari, dove viene indicato sia il livello di esperienza che il tipo di impiego. (Tabella 3.1)

Tabella3.1

	CT	FL	FT	PT
EN	65234	75000	80497	38885
MI	78600	41616	105321	42561
SE	97500	53333	153214	0
EX	416000	0	192975	0

La tabella si può rappresentare anche in seguente grafico a barre: (Figura 3.4)

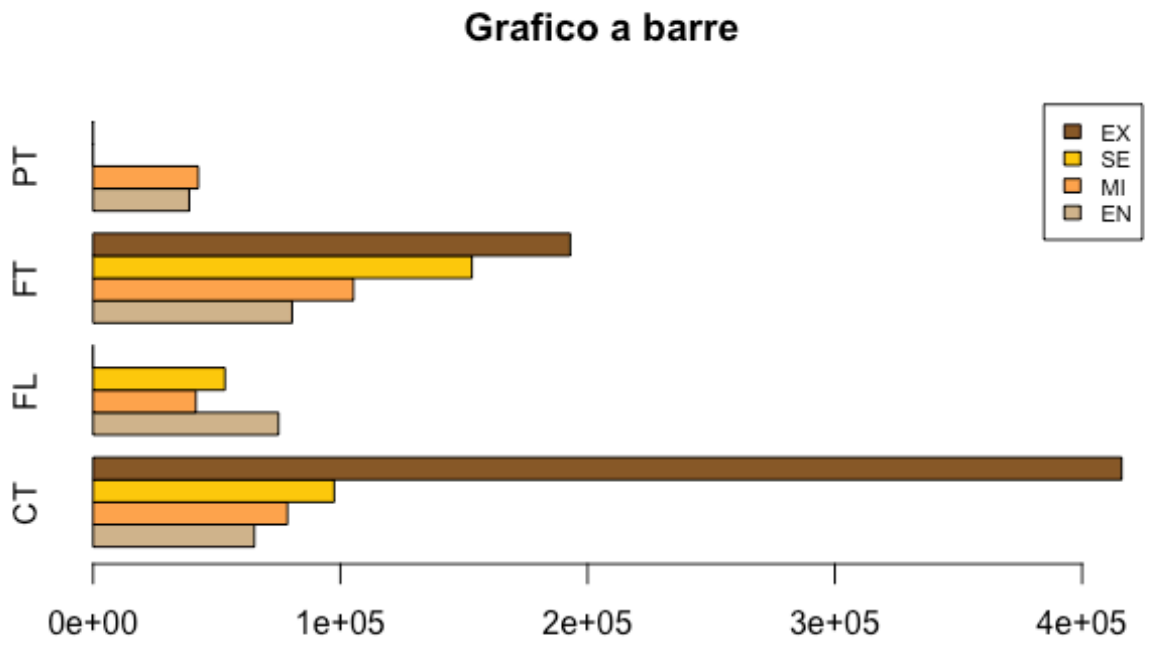

Dalla grafico, possiamo capire che i data scientist di livello esecutivo con contratto base hanno i salari più alti e in seguente sono quelli di livello esecutivo con full-time e il terzo sono quelli di livello senior con full-time. Quindi possiamo capire che in generale chi ha il livello più alto, ha il salario alto.

Inoltre, ci sono altri 3 diversi modi per rappresentare la tabella:

Prima di rappresentare i 3 modi diversi, possiamo creare una tabella che contiene il risultato totale (Tabella3.2).

Tabella3.2

	CT	FL	FT	PT	Totale
EN	65234	75000	80497	38885	259616
MI	78600	41616	105321	42561	268098
SE	97500	53333	153214	0	304047
EX	416000	0	192975	0	608975
totale	657334	169949	532007	81446	1440736

1. Divido per la colonna marginale

	CT	FL	FT	PT	Totale
EN	0.25	0.29	0.31	0.15	1
MI	0.29	0.16	0.39	0.16	1
SE	0.32	0.18	0.5	0	1
EX	0.68	0	0.32	0	1
totale	0.46	0.12	0.37	0.06	1

La somma delle righe è uguale a 1 e come interpretazione ad esempio: fra i salari dei data scientisti di livello base, il 25% è CT, il 29% è FL, IL 31% è FT e il 15% è PT.

2. Divido per la riga marginale

	CT	FL	FT	PT	Totale
EN	0.1	0.44	0.15	0.48	0.18
MI	0.12	0.24	0.2	0.52	0.19
SE	0.15	0.31	0.29	0	0.21
EX	0.63	0	0.36	0	0.42
totale	1	1	1	1	1

La somma della colonna è uguale ad 1 e come interpretazione ad esempio: fra i salari dei data scientist di CT, il 10% è EN, il 12% è MI, il 15% è SE, il 63% è EX.

3. Divido per il totale

	CT	FL	FT	PT	Totale
EN	0.05	0.05	0.06	0.03	0.18
MI	0.05	0.03	0.07	0.03	0.19
SE	0.07	0.04	0.11	0	0.21
EX	0.29	0	0.13	0	0.42
totale	0.46	0.12	0.37	0.06	1

La somma totale è uguale ad 1, come interpretazione ad esempio: il 13% di salari dei data scientist è di livello esecutivo ed è full-time. E possiamo capire dalla tabella anche che la classe cha ha i salari più alto è le persone con EX e CT, che occupa il 29%.

3.2. Analisi del fenomeno secondo il livello di esperienza

Il fenomeno può essere analizzato anche secondo una sola variabile, in questa paragrafo analizziamo secondo il livello di esperienza.

	salario	percentuale
EN	259616	0.18
MI	268098	0.19
SE	304047	0.21
EX	608975	0.42
totale	1440736	1

Secondo la tabella, la classe ha il salario più alto è EX, che occupa il 42%, invece la classe cha ha il salario più basso è EN, che occupa il 18%, però si avvicina al Mi che occupa il 19%.

Quest'osservazione si può rappresentare anche attraverso il grafico a barre e il grafico a torta.

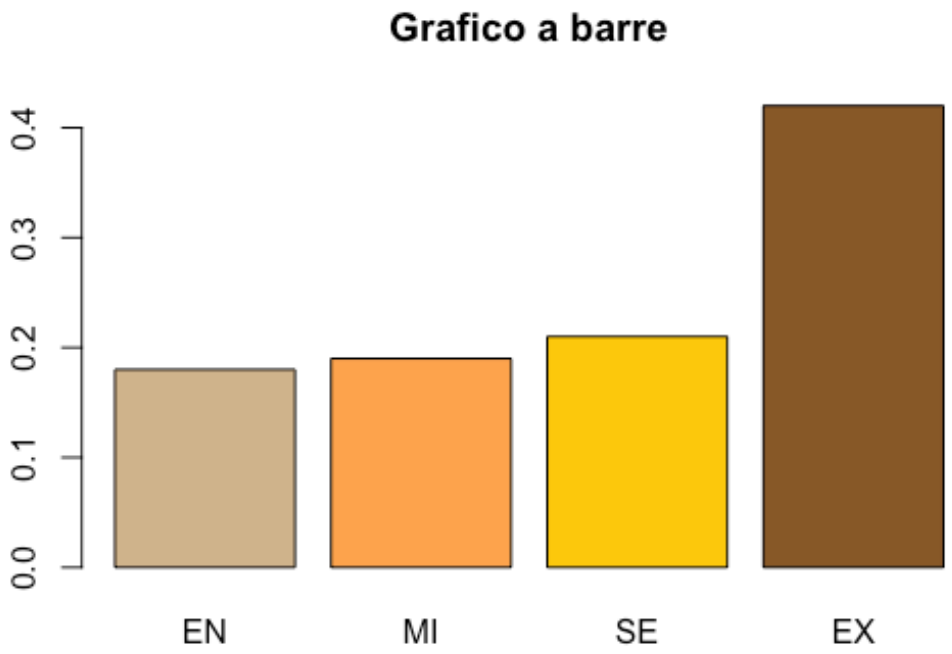

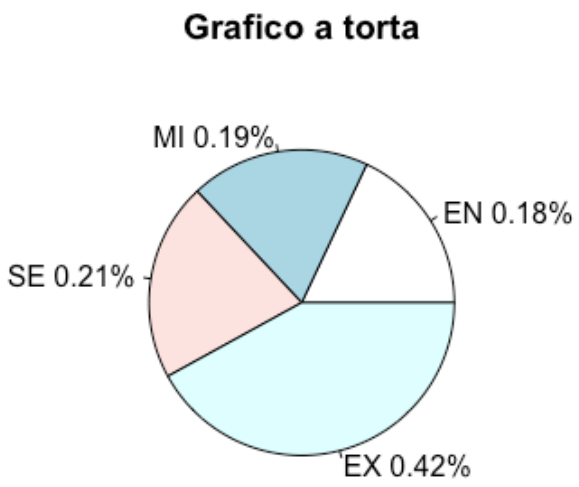

3.3. Analisi del fenomeno secondo il tipo di impiego

Il fenomeno può essere analizzato anche secondo una sola variabile, in questa paragrafo analizziamo secondo il livello di esperienza.

	salari	percentuali
CT	657334	0.46
FL	169949	0.12
FT	532007	0.37
PT	81446	0.06
Totale	1440736	1

Secondo la tabella, la classe ha il salario più alto è CT, che occupa il 46%, invece la classe cha ha il salario più basso è PT, che occupa solo il 6%.

Quest'osservazione si può rappresentare anche attraverso il grafico a barre e il grafico a torta.

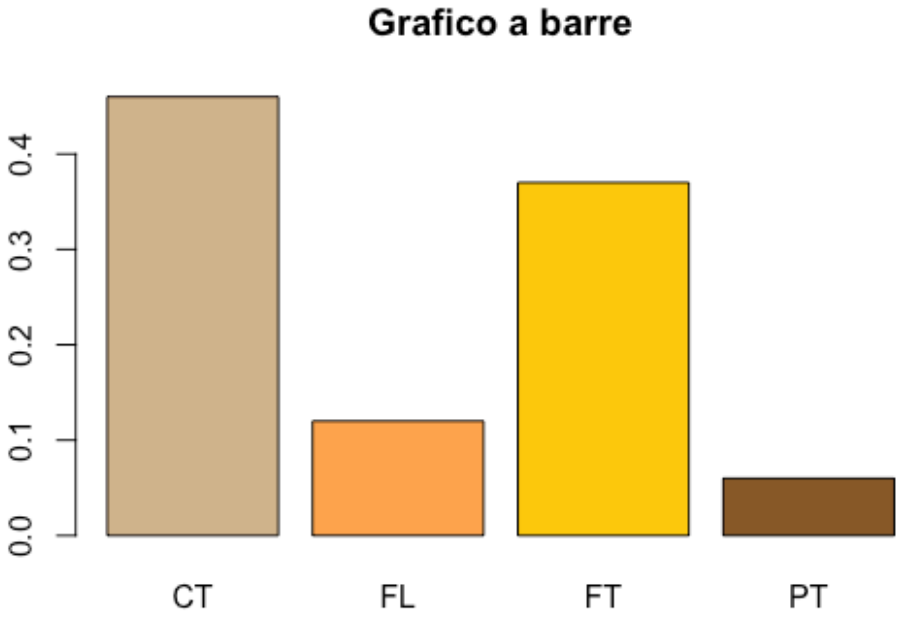
Grafico a barre
0.0
0.1
0.2
0.3
0.4
CT
FL
FT
PT

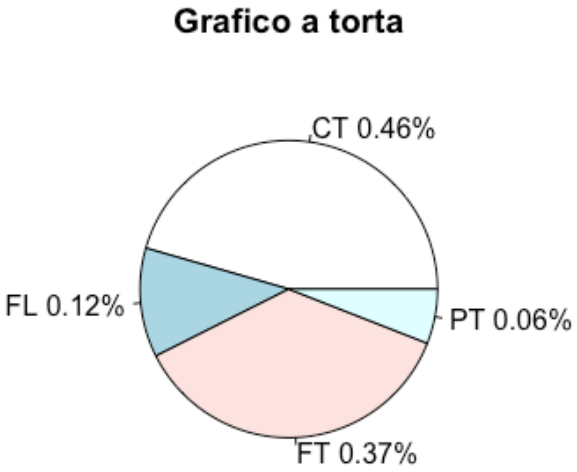
Grafico a torta
CT 0.46%
FL 0.12%
PT 0.06%
FT 0.37%